

Plano avançado — Abandono escolar em Roraima

Oct 7, 2026 · @Gustavo

A recomendação é mudar a pergunta do projeto: de "qual algoritmo prevê melhor a taxa" para "quanto do abandono é previsível, que alvo priorizar e quem cada critério deixa de fora". Com os dados que já estão no disco, um estimador de duas linhas iguala ou supera os modelos de ML. Priorizar por número de alunos, e não por taxa, dobra os alunos alcançados, mas quase exclui as escolas indígenas do ensino médio. Essa é a tese do artigo, e ela se fecha com uma previsão selada para 2026, conferida quando o Inep publicar as taxas em meados de 2027.

Onde o projeto está

A infraestrutura está pronta e o método está escrito; falta fechar o que o projeto vai afirmar.

Frente	Estado em 07/10/2026	Lacuna
Dados	Bootstrap reproduzível com manifesto sha256; base longitudinal 6.054 × 59, idêntica à do orientador	Sem matrícula nem estrato indígena (D8 em aberto); taxas por ano escolar ficam em <code>interim/</code> e não entram na base
Método	Proposta do orientador (17/09) e <code>docs/metodologia_variaveis.md</code> : baselines B0–B4, cenários A e B, experimentos E0–E9, equidade por estrato	Ainda não executados: B2, cenário B, modelo misto, calibração, peso por matrícula (E9)
Modelagem	<code>v1_corrigido</code> : pipeline sem vazamento, walk-forward, Recall@K, importância por permutação	Os modelos não superaram a persistência de forma estável; R ² negativo em 2 de 4 folds nos anos finais e em 3 de 4 no ensino médio
Escrita	Estrutura de artigo proposta pelo orientador (§18 da proposta)	Sem tese definida; prazos da disciplina e do PIBIC não registrados (Q6)

Três pontos pedem correção antes de qualquer novo experimento:

- **Dois conjuntos de documentos divergem.** Os relatórios 00-07 deixam a matrícula fora do enriquecimento e dizem que a evasão só existe agregada. O repositório já propõe matrícula e estrato (D8, P018, E9), e a pasta `Teste censo 2021` tem as taxas de transição por município. A fonte de verdade deve ser `docs/` do repositório.
- **O teste bloqueado já foi usado.** A proposta reserva 2024→2025 para uma única avaliação final. Os notebooks `v1`, `v1_old` e `v1_corrigido` já o avaliaram, e os diagnósticos deste plano também.
- **O recorte declarado não é o da base.** O grupo fala em 9º ano a 3ª série; o alvo de anos finais cobre do 6º ao 9º.

O que os dados mostram

Treze achados, todos obtidos com os arquivos de 2019–2025 que já estão no disco. São exploratórios e saem do script `diagnosticos_plano.py`.

#	Achado	Número	O que muda no plano
1	As escolas são pequenas	Mediana de 80 alunos nos anos finais (AF) e 62 no ensino médio (EM); 31% e 43% das escolas-ano têm até 50	Um aluno vale 1,2–1,6 p.p. na escola mediana; taxa de escola pequena é ruidosa
2	Só parte da variação é previsível	Dentro do ano, 2022–2025: 37–38% é diferença persistente entre escolas, 23–28% é ruído binomial, o resto é choque transitório	O teto de qualquer modelo anual é baixo; medir o teto vira resultado
3	O risco é um nível estável, não uma tendência	Spearman entre anos: 0,40–0,42 a 1 ano e 0,28–0,40 a 3 anos; na distorção idade-série (TDI), 0,82–0,84 a 1 ano	Média longa com encolhimento vale mais que o último ano; a TDI funciona como memória da escola
4	O simples empata ou vence	MAE médio em 4 folds (p.p.): taxa acumulada encolhida 2,94 no AF e 5,60 no EM; RandomForest 3,53 e 6,39; persistência 3,40 e 6,67	O baseline a bater passa a ser o encolhimento, não a persistência

#	Achado	Número	O que muda no plano
5	Estamos perto do teto	Sobreposição do top-30 por taxa: 0,40-0,45 nos melhores previsores simples; 0,49-0,51 numa simulação em que o risco persistente é conhecido	Com dado anual sobra pouco a ganhar; o salto vem de dado dentro do ano letivo
6	O alvo pesa mais que o algoritmo	Lista de 30 escolas por taxa alcança 23% dos alunos que abandonam no ano seguinte; por contagem esperada, 40% (AF) e 50% (EM); trocar o algoritmo muda até 2-3 p.p.	Alvo principal passa a ser contagem; a métrica operacional vira "captura de alunos@K"
7	Só o tamanho já explica muito	As 30 maiores escolas alcançam 27% (AF) e 42% (EM)	Todo resultado de contagem é comparado a "só o porte"
8	Contagem pura exclui as indígenas	No EM, a lista por contagem tem 1 escola indígena em 30 e alcança 4% dos abandonos dessas escolas; com cota por estrato, 9 escolas e 30%, com captura total de 45%	A priorização estratificada entra no desenho, não só na avaliação
9	Lista por taxa regride à média	Top-30 por taxa de 2023: 12,6% → 6,1% em 2024 (AF) e 20,6% → 10,6% (EM), sem intervenção	Antes e depois de escolas priorizadas não mede efeito; piloto precisa de sorteio
10	Roraima divergiu do país em 2025	EM público: Brasil 3,5% → 2,5%; Roraima 3,8% → 4,1%. Na capital, 2,9% → 2,3%; nas escolas indígenas, 6,4% → 7,9%	É o contexto e a motivação do artigo; rende uma frente descritiva própria
11	O problema está no ensino médio e em turmas pequenas	Em 2025: abandono de 4,2% na 1ª série, 4,1% na 2ª, 3,7% na 3ª e 2,4% no 9º ano; cerca de 20 alunos por série na escola mediana	Modelo por série isolada não se sustenta; o recorte 9º-3ª entra como contagem somada por escola


#	Achado	Número	O que muda no plano
12	Evasão é o dobro do abandono	2021→2022, rede pública de Roraima: evasão de 10,8% no EM (17,0% na 2ª série) contra abandono de 5,1% em 2021	Evasão ganha frente própria, com dado municipal e, depois, dado de aluno
13	Planejar dois anos à frente custa pouco	Com encolhimento, o Spearman cai de 0,42–0,45 (t+1) para 0,36–0,37 (t+2)	O dado público só permite planejar t+2; os dois horizontes são avaliados

Cada fold tem cerca de 240 escolas no AF e 170 no EM. Diferenças de poucos pontos estão dentro do ruído, e o plano trata esses números como hipóteses a confirmar. As tabelas completas estão na aba Evidências.

Roraima e Brasil

Em 2025 o abandono caiu no Brasil (2,5%) e subiu em Roraima (4,1%)

Taxa de abandono no ensino médio da rede pública, em %



Inep, taxas de rendimento por UF, rede pública, 2019–2024 · 2025: divulgação do Censo Escolar 2025; o valor de Roraima confere com a reconstrução por escola (4,05%)

A maior parte da queda desde 2022 aconteceu em 2023, antes do Pé-de-Meia. Nos anos finais, que o programa não cobre, a taxa de Roraima caiu de 3,7% para 1,7% entre 2022 e 2024, proporção parecida com a do ensino médio. Por isso o plano trata o programa como contexto e não estima seu efeito.

A tese do artigo

O artigo defende que, numa rede de escolas pequenas, o alvo e o critério de priorização importam mais que o algoritmo, e mede quanto. Título de trabalho: **Taxa ou contagem? Limites da previsão e dilemas de priorização do abandono escolar em Roraima.**

Quatro contribuições, cada uma ligada a uma análise que os dados já permitem:

1. **Teto de previsibilidade.** Quanto da variação anual do abandono por escola é persistente, quanto é ruído de escola pequena e quanto é choque. Usa denominadores reconstruídos e mostra a que distância do teto ficam os previsores.
2. **Simple contra complexo, em teste honesto.** Encolhimento empírico-bayesiano e modelo hierárquico contra RandomForest e boosting, em walk-forward, com intervalo por reamostragem de escolas.
3. **O alvo como decisão.** Taxa e contagem geram listas quase disjuntas: em 2025, 12 escolas em comum em 30 no AF e 11 no EM. O artigo traça a fronteira entre alunos alcançados e presença de escolas indígenas e rurais.
4. **Previsão prospectiva.** As previsões para 2026 são seladas antes da divulgação do Inep e conferidas depois.

O achado "modelos não batem a persistência" deixa de ser um resultado fraco e vira o ponto de partida. A proposta do orientador já previa isso no §20: um estudo negativo bem validado tem valor.

Trabalho	O que mostrou	Diálogo com o artigo
Salganik et al. (2020), PNAS	160 equipes previram seis desfechos de vida; os melhores modelos ficaram pouco acima de um baseline simples	Mesmo padrão em dado administrativo por escola
Perdomo et al. (2023)	No sistema de alerta de Wisconsin, direcionar pela escola e pelo distrito seria tão eficiente quanto o escore individual	Sustenta a unidade escola-ano
Andrade e Soida (2015), Estudos Econômicos	Rankings de escolas pelo Enem oscilam muito nas escolas pequenas e persistem pouco	Precedente brasileiro para o ruído de escola pequena e a regressão à média; a referência clássica é Kane e Staiger (2002)

Trabalho	O que mostrou	Diálogo com o artigo
Cossi et al. (2024), BID	Em Sergipe, regras simples de frequência por aluno, avaliadas com sorteio de 299 escolas, reduziram o risco de abandono	Modelo para o passo seguinte e para o desenho do piloto
Almeida e Mussato (2023)	Infraestrutura das escolas estaduais de EM de Roraima em quatro regiões; 71 das 165 eram indígenas em 2019	Fornece os estratos e o interlocutor local: os autores são da Seed/RR

A tese cai se, com a série longa ou o enriquecimento, um modelo de ML superar o encolhimento além do intervalo de confiança na captura de alunos. Nesse caso o artigo relata isso; o protocolo rende resultado publicável nos dois cenários.

O artigo não trata de causalidade, não prevê aluno e não publica lista de escolas.

Decisões para levar ao orientador

Dez decisões destravam o resto; as quatro primeiras são pré-requisito de todas as trilhas.

#	Decisão	Recomendação	Evidência
1	Papel de 2024→2025	Tratar como validação e declarar no artigo que foi usado no desenvolvimento	Três notebooks e os diagnósticos já o avaliaram
2	Teste final	2025→2026, prospectivo: congelar a especificação e selar as previsões, com hash e data, antes da divulgação do Inep	É a única transição intocada; as taxas de 2025 saíram no fim de junho de 2026
3	D8: matrícula e estrato	Aprovar já e ampliar: guardar também o denominador reconstruído e as contagens de aprovados, reprovados e abandonos	A reconstrução reproduz a taxa oficial da UF com diferença de até 0,1 p.p. em 2019–2024
4	Alvo principal	Contagem esperada de abandonos por escola; a taxa fica como alvo secundário	Dobra a captura de alunos; a taxa sozinha premia escola minúscula (P018)

#	Decisão	Recomendação	Evidência
5	Estrato	Usar no desenho da lista, com cota por estrato, e não como preditor	Contagem pura deixa 1 escola indígena em 30 no EM
6	Recorte 9 ^o -3 ^a	Manter AF e EM como unidades de modelagem; reportar 9 ^o -3 ^a como contagem somada por escola; série a série só de forma agregada	Cerca de 20 alunos por série na escola mediana; matrícula por série só existe de 2023 em diante
7	D11: série 2007-2018	Aprovar, mas só executar depois de congelar o protocolo com 2019-2025	Triplica as transições e tira o peso da pandemia; o ganho de ordenação é limitado pelo teto
8	Pandemia (Q4)	Manter 2020-2021 na base; a sensibilidade S1-S4 segue como previsto	A anomalia é 2020, não 2022; a ordenação das escolas resiste, o nível não
9	Limiar de alto risco (Q10)	Trocar o limiar fixo pela capacidade K e por curvas de captura, com K de 10 a 50	Limiar em taxa muda a cada ano e recai em escolas pequenas
10	Horizonte	Avaliar t+1 e t+2	Com dado público, só t+2 serve para planejar o ano letivo

Sobre a decisão 10: as taxas do ano t saem em meados de t+1. Uma previsão para t+1 feita com dado público chega com o ano letivo pela metade. O horizonte t+1 só é operacional se a Seed/RR ceder o dado interno do fechamento do ano letivo.

Trilhas de trabalho

Dez trilhas, em ordem de dependência; T0 a T4 bastam para o artigo principal e usam só o que já está no disco.

Trilha	O que faz	Entregável	Pronto quando
T0 Protocolo e teste prospectivo	Congela alvo, métricas, folds e a comparação primária antes de novos experimentos; adota o checklist REFORMS	<code>docs/PROTOCOLO.md</code> e arquivo de previsões de 2026 com hash	O orientador aprova e o hash é publicado antes da divulgação do Inep
T1 Base v2 com contagens	Junta matrícula, estrato oficial, denominador reconstruído, contagens e taxas por série	Base v2 no manifesto	A taxa ponderada bate com a da UF em 2019–2024, com diferença de até 0,1 p.p.
T2 Teto de previsibilidade	Decompõe a variância em persistente, binomial e transitória; simula o melhor desempenho possível por métrica	Tabela e figura do teto	Há intervalo por reamostragem de escolas e teste de sobredispersão
T3 Previsores parcimoniosos	Encolhimento beta-binomial, modelo hierárquico e modelo conjunto AF+EM; ML entra como comparador	Tabela walk-forward com intervalo pareado	A comparação primária do protocolo está concluída
T4 Avaliação por decisão	Captura de alunos@K, fronteira taxa × contagem, cotas por estrato, calibração e intervalo por escola, horizontes $t+1$ e $t+2$	Figura da fronteira e tabela por estrato	Os resultados se mantêm entre folds e entre valores de K

Trilha	O que faz	Entregável	Pronto quando
T5 Série longa (D11)	Estende indicadores e matrícula para 2007–2018	Painel 2007–2025	As rupturas de esquema estão registradas e o protocolo já estava congelado
T6 Enriquecimento parcimonioso	Testa cinco blocos pré-definidos contra o baseline: composição, infraestrutura, docentes, gestão e calendário	Ganho incremental por bloco	Cada bloco tem intervalo; nada foi escolhido por correlação com o alvo
T7 Roraima em contexto	Séries por estrato e por série; comparação com Brasil e Norte; EM e AF antes e depois de 2024	Seção descritiva e texto de política	Os placebos anteriores a 2024 foram feitos e os limites estão declarados
T8 Do abandono à evasão	Painel municipal das taxas de transição; progressão aparente da coorte; pedido de dado de aluno	Seção de evasão e pedido protocolado	A relação abandono → evasão está estimada por município
T9 Observatório e piloto	Listas por estrato com incerteza, ficha por escola e desenho de piloto com sorteio	Protótipo discutido com a Seed/RR	A revisão ética e a consulta às organizações indígenas foram feitas

T0: como selar a previsão

O arquivo traz, para cada escola pública com AF ou EM em 2025, a taxa e a contagem esperadas para 2026, o intervalo e a posição em cada regra de lista. O sha256 vai para o manifesto, com tag no git e depósito datado em repositório público como OSF ou Zenodo. Prazo sugerido: março de 2027, três meses antes da data em que o Inep divulgou as taxas em 2026.

T1: o denominador

As taxas saem sem denominador (P018). O denominador é o inteiro compatível com as três taxas de uma casa decimal mais próximo da matrícula do Censo. Ele foi achado em 94% das escolas-ano e fica entre 0,92 e 1,04 da matrícula em 90% dos casos. Por série, a matrícula só existe de 2023 em diante; antes disso a reconstrução pela média de alunos por turma acerta cerca de 70% dos casos e deve ser tratada como aproximação.

T3: o baseline a bater

O encolhimento puxa a taxa acumulada de cada escola para a taxa da rede, com força inversa ao número de alunos observados:

$$\hat{p}_i = \frac{\sum_t B_{it} + m \cdot p_0}{\sum_t n_{it} + m}$$

B é a contagem de abandonos, n o denominador, p0 a taxa da rede e m o peso do prior, estimado por momentos: nos diagnósticos, de 50 a 70 alunos no AF e de 26 a 34 no EM. A contagem esperada é essa taxa vezes a matrícula do ano. O modelo hierárquico generaliza a mesma ideia com efeitos de escola, município, estrato e ano, e com a TDI como covariável. O modelo conjunto se justifica porque 88% das escolas de EM também têm anos finais e o abandono das duas etapas na mesma escola tem Spearman de 0,43 a 0,65.

A comparação primária fica fixada antes de rodar: encolhimento contra o melhor modelo de ML, em captura de alunos@30 e MAE, com reamostragem pareada de escolas sobre todos os folds.

T6: os cinco blocos

- Composição: proporção de matrícula noturna, de alunos com 18 anos ou mais e de alunos indígenas.
- Infraestrutura: as quatro dimensões de Almeida e Mussato, com as mesmas 18 variáveis do Censo.
- Docentes: adequação da formação, regularidade e esforço docente.
- Gestão: complexidade de gestão da escola.
- Calendário: duração do ano letivo, pelas datas de início e término do Censo.

A expectativa é de ganho pequeno na previsão. O valor desses blocos está em descrever as escolas priorizadas, não em melhorar a lista.

T7: o que dá para dizer sobre o Pé-de-Meia

Os dados permitem descrever, não atribuir. A queda de 9,1% para 4,5% ocorreu em 2023, antes do programa. Entre 2022 e 2024 os anos finais caíram 54% e o ensino médio 58%. Em 2025 a taxa do ensino médio subiu fora da capital. O estudo do Centro de Evidências

da Educação Integral (Insper e parceiros), divulgado em março de 2026, é uma simulação prévia, e seus autores dizem que a avaliação com resultados observados só será possível a partir do quarto ano.

T8: evasão

As taxas de transição do Inep vão de 2007–2008 a 2021–2022; o arquivo por município de 2021–2022 já está na pasta `Teste censo 2021`. A progressão aparente da coorte na rede pública foi de 0,80 a 0,82 da 1ª para a 2ª série e de 0,84 a 0,86 da 2ª para a 3ª em 2023–2025. Evasão por escola exige dado de aluno, a pedir à Seed/RR ou ao serviço de dados protegidos do Inep; por isso esta trilha não bloqueia o artigo principal.

T9: piloto

A taxa média das 30 escolas do topo cai de um terço a dois terços no ano seguinte, sem nenhuma ação. Qualquer piloto que compare antes e depois vai parecer um sucesso. O desenho recomendado sorteia, entre as escolas elegíveis de cada estrato, quais recebem a ação primeiro, como no estudo de Sergipe.